

杨启铎 | AI Agent / 大模型应用开发

姓名: 杨启铎 | 性别: 男 | 英语水平: CET6 | GitHub: github.com/TheodoreYang6
电话: 18392430868 | 电子邮箱: qdyang@mail.nwpu.edu.cn | 政治面貌: 中共党员



教育背景

2025.09 - 2028.06 | 西北工业大学 (985) | 网络与信息安全 硕士 | 主修: 机器学习、深度学习、自然语言处理、强化学习
2021.09 - 2025.06 | 中国民航大学 | 信息安全 本科 | GPA: 3.7 / 4.0 (前 15%) | 三年获得奖学金

项目经历

Horizon-Agent • 溯证智搜 | 2026.02 - 2026.04 | AI Agent / 个人独立开发 | GitHub: [TheodoreYang6/HorizonRL-Agent](https://github.com/TheodoreYang6/HorizonRL-Agent)

- 项目概述:** 面向复杂研究任务构建多阶段 LLM Agent 系统, 将自然语言问题拆解为可并发执行的研究 DAG, 打通任务拆解、工具调用、交叉验证、失败恢复、证据溯源与报告生成闭环。
- 技术栈:** Python、LangGraph、asyncio、FastAPI、SSE、SQLite、ChromaDB、DashScope Embedding、OpenAI SDK、DeepSeek
- **DAG 编排:** 设计 Planner / LLMPlanner + LangGraph 6 节点 DAG 编排器, 将复杂研究问题拆解为子任务依赖图, 封装 `plan_task` → `mark_ready` → `execute_batch` → `verify_batch` → `replan` → `finalize` 状态流转。
 - **工具调用:** 实现 AgentWorker + ToolManager 工具调用层, 统一接入 Web、Paper、Arxiv、Code、RAG、GitHub、RSS、PubMed 等工具/插件, 基于 asyncio、Semaphore、超时、重试与三态熔断保障多源调用稳定性。
 - **验证重规划:** 构建 Verifier-Replanner 反馈闭环, 使用 9 条规则 + LLM / Hybrid 复核识别 EMPTY_RESULT、TOOL_ERROR、INCOMPLETE 等异常, 并生成 RETRY / ADD / REMOVE / REORDER 修复动作。
 - **证据记忆:** 设计 EvidenceItem / SearchProvenance 证据溯源模型, 将来源、时间、检索引擎、query 与相关性分数写入报告引用; 结合 L1 / L2 / L3 记忆、DashScope Embedding + ChromaDB 支撑历史经验检索与文档 RAG。
 - **服务化交付:** 搭建 FastAPI + SSE 服务层, 支持 SQLite 会话持久化、Token 级流式输出、文档上传检索、报告下载与可视化调用入口, 并通过 Pydantic V2 管理配置和接口契约。
 - **工程规模:** 按 53 个源文件、5 个插件、20 个测试文件 / 495 条测试用例组织工程结构, 覆盖编排、工具、验证、记忆、Web API 等核心模块, 提升个人独立项目的可维护性与可验证性。

OmniCart Agent • 豆仔购物智能助手 | 2026.04 - 2026.06 | AI Agent / Android 原生 / 字节跳动 AI 全栈挑战赛参赛项目

- 项目概述:** 面向电商购物前决策场景, 构建基于 rag 的多模态导购 Agent 系统, 实现「Android 原生客户端 + FastAPI Agent Runtime + Qwen 全栈模型 + RAG 证据检索 + 多维决策评分 + 多轮追问上下文管理 + 长期记忆管理 + 用户偏好」完整闭环。
- 技术栈:** FastAPI、LangGraph、RAG、Qwen、Qdrant、PostgreSQL、Redis; Kotlin、Jetpack Compose、Material 3
- **Android 原生客户端:** Kotlin + Jetpack Compose + Material 3 四 Tab 客户端, SSE 流式逐字渲染对话, 支持拍照/相册/语音多模态输入、商品详情 6 Tab、“问豆仔”聚焦分析、购物车联动、模拟结算与豆仔购物车操作、直接下单快速购买路径。
 - **记忆系统设计:** 分为短期会话层与历史消息层、用户偏好层三层架构。短期层承载约束累积、Q&A 链追踪、聚焦商品锁定与最近 3 轮摘要。历史层以永久存储完整对话, 支撑 Android 端历史列表、聊天恢复与继续追问。用户偏好负责存储用户长期偏好并用于推荐商品参考依据, 所有上下文读写统一到 ConversationService 单入口, 话题切换时自动检测品类变化并清空旧约束、追问时继承上一轮品类与预算。
 - **多 Agent 工作流编排:** 基于 LangGraph 构建 Router → Visual → Retrieval → Reranker → EvidenceCheck → Decision → Response → Guard 8 节点有状态 Workflow。Router 两层意图识别, 含闲聊检测与品类安全校验; Retrieval 实现 Qwen Embedding + Qdrant 块级语义检索 + 查询改写; Response 含幻觉检测与 6s 超时模板兜底。
 - **Evidence RAG:** 实现 Qwen Embedding + Qdrant 块级语义检索 + Qwen Reranker 精排的三阶段检索管线。原始商品文本拆分为独立 chunk 分别向量化存入 Qdrant, 检索时对 query 做 LLM 改写提取关键词, 块级 ANN 搜索后按 max_score 聚合, Reranker 对候选做交叉编码精排。
 - **6 维决策评分引擎:** 语义相关度(余弦相似度校准曲线 $0.68 + 0.38 \times \cos_sim$) + 预算匹配 + 用户口碑(Bayesian 平滑) + 性价比(29 品类基准) + 规格品质(LLM 关键词 + 描述丰富度兜底) + 场景适配 - 风险扣分(max 0.20)。硬约束 + 软评分双层过滤, 5 级推荐等级, 所有维度确定性可复算。
 - **端到端数据闭环:** 12 组 REST API 串联客户端与 Agent Runtime, 7 表 PostgreSQL 承载用户、商品、购物车、地址与对话历史全量持久化, Qdrant 向量库支撑块级语义检索, Redis+ 缓存查询改写与检索结果。支持真实 Qwen API 与本地 Mock 规则引擎双模式一键切换。

专业技能

- **编程与工程:** 熟练 Python / Linux / Git / Docker / Shell, 具备模块化设计、异步编程、配置管理、日志系统、自动化测试与项目交付经验; 熟悉 C++ / Java。具备独立开发、项目负责人组织开发能力, 具备使用 codex / claude 等工具辅助编程与解决问题的能力。
- **AI Agent 与 RAG:** 熟悉 LangGraph / LangChain、ReAct、Plan-Execute、Tool Calling、Memory、Verifier-Replanner 等范式, 具备 Agent 工作流编排、工具调用、失败恢复、结果验证与 RAG 证据溯源经验。
- **大模型应用:** 掌握 Transformer、Self-Attention、KV Cache、Token Streaming 等原理, 熟悉 Qwen / DeepSeek / LLaMA 生态, 具备 Prompt Engineering、结构化输出、Function Calling、vLLM 与 OpenAI-compatible API 接入经验。
- **机器学习基础:** 掌握常见机器学习算法、模型评估、特征工程与 PyTorch 实现, 了解 SFT / RLHF / DPO、LoRA / QLoRA 等训练和微调流程。